

Un export du thésaurus — esquisse et questions ouvertes

Xavi, 28 août 2026. À lire avec les deux fichiers joints.

CE QUE C'EST, ET CE QUE CE N'EST PAS

Ce n'est **pas** un export. C'est une esquisse de 26 descripteurs sur 620, fabriquée depuis l'extérieur. Elle est incomplète par construction, et elle l'est de façon intéressante : ce qui lui manque, c'est exactement ce qu'on ne peut pas savoir sans avoir accès au site.

Sur quelle copie elle est faite. Aspiration du 27 août 2026, la plus récente dont je dispose ; la date est inscrite dans les deux fichiers. Si des corrections ont été portées à la source depuis, c'est la source qui a raison. Les défauts de libellé ne sont pas l'objet de cette note : ils font l'objet d'un relevé séparé, qui se refait à chaque aspiration.

Elle est faite pour qu'on regarde ensemble les trous, pas pour être adoptée.

Deux fichiers, le même contenu :

FICHIER	POUR QUOI FAIRE
ficedl_thesaurus_ESQUISSE.csv	s'ouvre dans un tableur ; c'est la version qui se lit
ficedl_thesaurus_ESQUISSE.jsonld	du SKOS, pour les machines ; c'est la version qui sert

Le CSV est en ; avec BOM, donc il s'ouvre correctement dans LibreOffice comme dans Excel sans réglage.

CE QUE L'ASPIRATION SAIT DÉJÀ FAIRE

Sur les 620 fiches :

- 462 portent un bloc de traduction, en dix langues plus le grec romanisé ;
- 2 842 liens vers six catalogues — CCL, CIRA de Lausanne, CIRA de Marseille, Placard, Cartoliste, archives du *Monde libertaire*. C'est, à mon sens, la partie la plus précieuse de l'ensemble, et celle dont personne ne parle ;
- 227 sujets, 234 noms géographiques, 158 dates, un descripteur dans deux facettes.

Tout cela sort proprement. Le reste, non.

CE QUE JE NE PEUX PAS TRANCHER DEPUIS DEHORS

Huit questions. Pour chacune j'ai mis une proposition dans les fichiers, pour qu'on ait quelque chose de concret à corriger — mais aucune n'est à moi.

1. Les identifiants

Aujourd'hui un descripteur s'atteint par `spip.php?mot87`. Ça marche, mais c'est un paramètre d'URL produit par le moteur : le jour où le site change de moteur, toutes les adresses cassent, et avec elles tous les alignements

que d'autres auront construits dessus.

Ce que j'ai mis dans l'esquisse : <https://thesaurus.ficedl.info/id/mot87>. On garde `motNN`, qui existe déjà et que les autres sites de la fédération citent, mais on le détache du moteur.

Ce que je ne sais pas : si SPIP peut servir une adresse pareille, et si ça vaut le dérangement.

2. La hiérarchie — vocabulaire précoordonné, et une convention de nommage

Écrit après ton courriel du 28, qui montre le balisage de la source : les niveaux sont des blocs `<multi>` séparés par `~:`. Ça change la question, donc je la repose autrement.

Les libellés composent : « art : affiches », « économie : agriculture ». J'ai essayé de reconstituer un arbre en recollant les segments. Sur les **148** descripteurs à parent annoncé :

- **93** ont un parent qui existe tel quel comme descripteur ;
- **45** de plus se résolvent si l'on accepte la convention « **X (généralités)** » — « art : affiches » sous « art (généralités) », et de même pour *économie*, *littérature*, *communication*, *mouvement anarchiste* ;
- **10** ne se résolvent par aucune des deux règles. Ils tiennent en quatre segments : « **guerres** » (7 fois), « art : courants », « guerres : Afghanistan », « guerres : Algérie ».

Autrement dit, ce n'est pas un arbre cassé : c'est un vocabulaire **précoordonné**, où le segment de tête est un morceau de libellé partagé et non un concept — sauf quand il en existe une forme « (généralités) », auquel cas c'en est un.

Les deux questions, et elles sont éditoriales, pas techniques :

1. **Est-ce que « X (généralités) » est bien le sommet de branche ?** Si oui, je peux écrire 138 relations sur 148 en toute honnêteté, et l'export devient d'un coup beaucoup plus utile.
2. **Que faire des quatre segments restants ?** Créer « guerres (généralités) », ou déclarer que ce sont des morceaux de libellé et rien d'autre ? Depuis dehors, les deux se ressemblent exactement.

Dans l'esquisse, chaque relation écrite porte une `skos:editorialNote` disant qu'elle est **déduite**, et les cas irréductibles portent une note qui nomme le segment manquant.

3. La facette « dates »

158 descripteurs — un quart du thésaurus — sans aucun bloc de traduction. Mon aspiration ne leur trouve pas de libellé du tout (un défaut de mon côté, que je suis en train de corriger, mais la question reste).

Deux questions en une : ces fiches ont-elles un libellé canonique quelque part ? Et ont-elles leur place dans le même export que les sujets, ou sont-elles autre chose ?

4. Les liens vers les catalogues

2 842 liens, six catalogues. C'est le trésor, et c'est aussi ce qui bouge le plus : un catalogue qui change de logiciel les casse tous.

La question : est-ce qu'ils sortent dans l'export, ou est-ce qu'ils restent une affaire du site ? Je les ai mis en `rdfs:seeAlso`, ce qui est prudent — `skos:relatedMatch` dirait qu'il s'agit du même concept, ce que je ne peux pas affirmer.

5. L'astérisque — je la jetais, et je l'attribuais au portugais

Tu écris qu'elle marque un mot absent, à l'époque, de la liste d'origine du CIRA, et qu'elle est posée **hors** du bloc `<multi>`.

Les deux moitiés de cette phrase m'ont coûté cher. Mon racleur lit langue par langue en prenant tout ce qui suit `[xx]` jusqu'au crochet suivant ; comme `pt` est le dernier code du bloc, **tout ce qui traîne après `</multi>` lui tombe dessus**. Résultat : 27 astérisques comptées comme des défauts portugais, alors qu'elles ne sont ni des défauts ni portugaises. Même mécanisme pour deux parenthèses fermantes mutualisées. Après correction, le portugais tombe de 29 anomalies à 2.

Le signe qui aurait dû m'alerter : l'astérisque apparaît **toujours sur `pt` , jamais ailleurs**. Une faute de saisie ne choisit pas sa langue avec cette régularité ; un analyseur, si.

C'est corrigé — `ficedl_scrape_queue_hors_bloc.patch` — et l'astérisque devient une donnée : `skos:scopeNote` , « mot absent, à l'époque, de la liste d'origine du CIRA ».

La question qui reste : dans un export officiel, est-ce que cette marque sort comme donnée, ou appartient-elle à l'affichage ? Elle m'intéresse : c'est une trace de l'histoire du vocabulaire, et ce genre de chose ne se retrouve jamais une fois perdu.

6. Le grec romanisé

Il est stocké à part de la langue grecque. Je l'ai écrit `el-Latn` , qui est une étiquette de langue légitime — mais si c'est un secours d'affichage plutôt qu'un libellé à part entière, il ne faut pas le sortir comme les autres.

Ça rejoint ta propre remarque sur *mot292* : un ajout mutualisé pour toutes les langues pose un problème particulier au grec, qui n'écrit pas en alphabet latin. Un export explicite ne le résout pas, mais au moins il le rend visible au lieu de le noyer dans une chaîne d'affichage.

7. La licence, écrite dans le fichier

La réponse reçue en juin — *pas de droits dessus, tout le monde peut le partager, à condition que les évolutions se fassent collectivement* — est la bonne, et je la reprends telle quelle. Mais elle est informelle, et je ne peux pas la citer comme une position de la fédération.

Une phrase dans le fichier lui-même la rendrait citable par tout le monde, une fois pour toutes. J'ai laissé l'emplacement, avec un « à fixer » dedans.

8. Comment le fichier se régénère

Un dump une fois, qui vieillira ? Ou un squelette SPIP qui imprime les mêmes termes en CSV au lieu de HTML, et qui est donc juste à jour ?

La seconde solution règle aussi un problème qui n'est pas le mien : le site a été lourdement moissonné par des robots, et mes propres aspirations y ont contribué — 620 pages à chaque passage. Un export, c'est **une** requête au lieu de 620, par consommateur et par mise à jour. Ça soulage d'abord celui qui publie.

Cette question-là, je ne peux pas y répondre du tout : je n'ai jamais vu ce site de l'intérieur.

CE QUE ÇA COÛTE, ET CE QUE JE PEUX FAIRE

De mon côté : le racleur est écrit, il tourne, il est à toi si tu le veux. Je peux produire l'export complet des 620 dans les deux formats dès que les huit questions ci-dessus ont une réponse — c'est une soirée.

De ton côté : un squelette SPIP, si c'est la voie retenue. Une demi-journée, je suppose, mais c'est toi qui sais.

Ce que je ne ferai pas : mettre le fichier en ligne ailleurs qu'à côté des pages dont il sort. Un export hébergé loin de sa source devient une seconde version, donc un fork — et ce serait un comble de l'introduire en croyant rendre service.